

12. cvičení z PSt — 7. 5. 2026

Říct: Vypsané definice, snažím se držet skript, kapitola 12, resp. 12.2

Definice 1. Necht $\theta \in \Theta$ je nějaký (nám neznámý) parametr, který udává nějaké rozdělení F_θ . Definujeme

- *náhodný výběr* jako posloupnost nezávislých n.v. $X_1, \dots, X_n \sim F_\theta$ reprezentující naměřená data,
- *estimátor* jako funkci $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n) \in \Theta$ reprezentující odhad hodnoty θ z naměřených dat.

Říct: Tj my v modelech předpokládáme, že θ známe (resp. θ je „cokoliv“), to nám určuje pravděpodobnostní prostor (tj není náhodné!) a z toho pak $X_1, \dots, X_n$ jsou náhodné veličiny, a estimátor $\hat{\theta}$ je funkce těchto veličin, tj. opět náhodná veličina.

Říct: Toto používáme na evaluaci jak dobrý je estimátor:

Definice 2. Pro estimátor $\hat{\theta}$ definujeme

- *bias* (vychýlení) jako $\text{bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$,
- *varianci* (rozptyl) jako $\text{var}(\hat{\theta}) = \mathbb{E}\left((\hat{\theta} - \mathbb{E}(\hat{\theta}))^2\right)$,
- *střední kvadratickou chybu* (MSE) jako $\text{MSE}(\hat{\theta}) = \mathbb{E}\left((\hat{\theta} - \theta)^2\right)$.

Věta 3. Pro každý estimátor $\hat{\theta}$ platí

$$\text{MSE}(\hat{\theta}) = \text{var}(\hat{\theta}) + \text{bias}(\hat{\theta})^2.$$

Říct: MLE je estimátor který jednoduše maximalizuje pravděpodobnost, že bychom dostali naměřená data. Idea je taková, že když jsme něco dostali, tak to asi bylo hodně pravděpodobné.

To může být blízko pravdě, ale ne nutně to má třeba nulový bias, jak jsme viděli minule v příkladu s Němci a tanky.

Definice 4. Necht $X_1, \dots, X_n \sim F_\theta$ je náhodný výběr. Definujeme *věrohodnost* (likelihood) estimátoru $\hat{\theta}$ pro $x = (x_1, \dots, x_n)$ následujícím způsobem:

- (1) pokud F_θ je *diskrétní rozdělení* s pravděpodobnostní funkcí p_θ , pak

$$L(x; \hat{\theta}) = p_{\hat{\theta}}(x_1) \cdot p_{\hat{\theta}}(x_2) \cdot \dots \cdot p_{\hat{\theta}}(x_n).$$

- (2) pokud F_θ je *spojité rozdělení* s pravděpodobnostní hustotou f_θ , pak

$$L(x; \hat{\theta}) = f_{\hat{\theta}}(x_1) \cdot f_{\hat{\theta}}(x_2) \cdot \dots \cdot f_{\hat{\theta}}(x_n).$$

V obou případech vyjadřuje to, jak pravděpodobná jsou námi naměřená data $x_1, \dots, x_n$, pokud je estimátor $\hat{\theta}$ roven skutečné hodnotě θ .

Definice 5 (MLE). *Maximum likelihood estimator* pokud jsme naměřili data $x = (x_1, \dots, x_n)$ je estimátor $\hat{\theta}_{\text{MLE}}$ definovaný tak, že maximalizuje likelihood, tedy

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\hat{\theta} \in \Theta} L(x; \hat{\theta}).$$

MLE, bias, rozptyl

1. Připomeňte si příklad z minulého cvičení: Chtěli jsme zjistit, kolik tanků Němci vyrobili, měli jsme přitom jen čtyři náhodná sériová čísla. Ujasněte si, co zde odpovídá pojům z definice 1.

Řešení: θ je počet tanků, náhodný výběr jsou ty naměřené hodnoty, a je rozdělen cca jako $X_i \sim \text{Bin}(\theta, 1/\theta)$ (až na to, že nemůžeme dvakrát ulovit tank se stejným číslem, takže reálně by to mělo být spíš hypergeometrické, ale toto je dobrá aproximace). $\square$

2. V přednášce jsme odvodili, že lineární regrese metodou nejmenších čtverců (least squares) je MLE, pokud předpokládáme, že šum ε_i v modelu $Y_i = ax_i + b + \varepsilon_i$ je gaussovský. Předpokládejme teď místo toho, že šumy ε_i mají Laplaceovu hustotu $f(\varepsilon) = \frac{1}{2}e^{-|\varepsilon|}$. Ukažte, že MLE odhad $(\hat{a}, \hat{b})$ minimalizuje

$$\sum_{i=1}^n |y_i - ax_i - b|.$$

Jinými slovy: z čtverců reziduí se stanou absolutní hodnoty reziduí. Výslednému vzorečku se říká *L1 regrese*. (*Hint dole*)¹

Řešení: Zlogaritmuje f a dostaneme téměř hned to co chceme. $\square$

3. Máme náhodný výběr $X_1, \dots, X_n \sim N(\mu, 1)$, kde μ je neznámé. Klasický MLE estimátor je $\hat{\mu}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n X_i$. Představme si ale, že z nějakého důvodu věříme, že skutečné μ je malé, a tak chceme odhad trochu „stáhnout“ k nule. Uvažujme proto estimátor $\hat{\mu}' = \frac{1}{2} \hat{\mu}_{\text{MLE}}$.

(a) Pro oba estimátory spočítejte jejich bias, varianci, a MSE.

Řešení: Pro μ_{MLE} : bias je nulový, variance je něco jako $\mathcal{O}(1/n)$ a MSE je tedy také něco takového.

Pro μ' : bias je $\frac{1}{2}\mu$, variance je čtyřikrát menší než pro μ_{MLE} a MSE z věty 3. $\square$

(b) Zkuste je porovnat.

Řešení: μ' má menší rozptyl, ale je biased. Pro malá μ a malé n má menší MSE. $\square$

4. Máme náhodný výběr $X_1, \dots, X_n \sim \text{Ber}(\theta)$, kde $\theta \in [0, 1]$ je neznámý parametr. Označme $S = \sum_{i=1}^n X_i$. Uvažujte čtyři estimátory parametru θ :

$$\hat{\theta}_1 = \frac{S}{n}, \quad \hat{\theta}_2 = \frac{S+1}{n+2}, \quad \hat{\theta}_3 = 0.42, \quad \hat{\theta}_4 = X_1.$$

(a) Které z těchto estimátorů jsou nestranné jako estimátory parametru θ ?

Řešení: $\hat{\theta}_1$ a $\hat{\theta}_4$ jsou nestranné.

$\hat{\theta}_2$ má bias $(1 - 2\theta)/(n + 2)$, takže je nestranný jen náhodou pro $\theta = 1/2$, ne pro všechna θ .

$\hat{\theta}_3$ je nestranný jen pro $\theta = 0.42$. $\square$

(b) Které z těchto estimátorů mají nulovou varianci pro libovolné θ ?

Řešení: pouze $\hat{\theta}_3$, protože je deterministický (není funkcí dat). Ostatní mají obecně nenulovou varianci. $\square$

(c) Pokud $\theta = 1/2$ a $n > 1000$, tipněte si, který estimátor má nejmenší MSE.

Řešení: pouze $\hat{\theta}_2$, Pro $\theta=1/2$ má nulový bias a

$$\text{var}(\hat{\theta}_2) = \frac{n}{4(n+2)^2} < \frac{1}{4n} = \text{var}(\hat{\theta}_1).$$

$\hat{\theta}_3$ má MSE $(0.42 - 0.5)^2 = 0.0064$ a $\hat{\theta}_4$ má MSE $1/4$. Pro θ dostatečně blízko 0.42 má $\hat{\theta}_3$ MSE blízko nule a vyhraje (rozdíl $|0.42 - \theta|$ musí být menší než $\sim \frac{1}{2\sqrt{n}}$). $\square$

(d) Vyberte si aspoň jeden estimátor $\hat{\theta}_j$ a spočítejte pro něj $\mathbb{E}(\hat{\theta}_j)$, $\text{bias}(\hat{\theta}_j)$, $\text{var}(\hat{\theta}_j)$ a $\text{MSE}(\hat{\theta}_j)$.

¹Dosaďte do funkce f a zlogaritmuje. Postup je téměř identický tomu co bylo na přednášce pro metodu nejmenších čtverců.

Řešení:

$$S \sim \text{Bin}(n, \theta), \quad \mathbb{E}(S) = n\theta, \quad \text{var}(S) = n\theta(1 - \theta).$$

$$\hat{\theta}_1 : \mathbb{E} = \theta, \quad \text{bias} = 0, \quad \text{var} = \theta(1 - \theta)/n, \quad \text{MSE} = \theta(1 - \theta)/n.$$

$$\hat{\theta}_2 : \mathbb{E} = (n\theta + 1)/(n + 2), \quad \text{bias} = (1 - 2\theta)/(n + 2), \quad \text{var} = n\theta(1 - \theta)/(n + 2)^2, \\ \text{MSE} = ((1 - 2\theta)^2 + n\theta(1 - \theta))/(n + 2)^2.$$

$$\hat{\theta}_3 : \mathbb{E} = 0.42, \quad \text{bias} = 0.42 - \theta, \quad \text{var} = 0, \quad \text{MSE} = (0.42 - \theta)^2.$$

$$\hat{\theta}_4 : \mathbb{E} = \theta, \quad \text{bias} = 0, \quad \text{var} = \theta(1 - \theta), \quad \text{MSE} = \theta(1 - \theta).$$

□

Testování hypotéz

5. Udělali jsme statistický test nulové hypotézy H_0 . Test vyšel signifikantně, H_0 jsme zamítli a p -hodnota byla $p = 0.01$.

U každého tvrzení označte, zda z výsledku logicky plyne.

(a) Vyvrátili jsme nulovou hypotézu H_0 , tj. určitě nemůže platit.

□ ano □ ne

(b) Zjistili jsme, že pravděpodobnost nulové hypotézy je 1 %.

□ ano □ ne

(c) Dokázali jsme alternativní hypotézu.

□ ano □ ne

(d) Zjistili jsme, že pravděpodobnost alternativní hypotézy je 99 %.

□ ano □ ne

(e) Když jsme zamítli H_0 , pravděpodobnost, že jsme se rozhodli špatně, je 1 %.

□ ano □ ne

(f) Výsledek je spolehlivý v tom smyslu, že kdybychom experiment mnohokrát opakovali, dostali bychom signifikantní výsledek v 99 % případů.

□ ano □ ne

Řešení: všechny odpovědi jsou NE.

$p = 0.01$ znamená $P(\text{data alespoň tak extrémní jako pozorovaná data} \mid H_0 \text{ platí}) = 0.01$, při splnění předpokladů testu. Není to $P(H_0 \mid \text{data})$, není to $P(\text{alternativa} \mid \text{data})$, není to pravděpodobnost chybného rozhodnutí a není to síla/replikovatelnost.

□

Tento dotazník dostali učitelé metodologie budoucích vědeckých pracovníků v medicíně; tipněte si, kolik procent učitelů a kolik procent studentů odpovědělo správně na všechny otázky.

Řešení: cca 10-20 % učitelů a 0 % studentů (Haller & Krauss, 2002).

□

6. Děláme 20 nezávislých testů. Předpokládejme, že všech 20 nulových hypotéz je ve skutečnosti pravdivých. Každý test děláme na hladině $\alpha = 0.05$.

(a) Jaká je pravděpodobnost, že jeden konkrétní test falešně zamítne svoji nulovou hypotézu?

Řešení: 0.05.

□

(b) Jaká je pravděpodobnost, že alespoň jeden z 20 testů falešně zamítne?

Řešení: $1 - 0.95^{20} \approx 0.642$. Pravděpodobnost žádného falešného zamítnutí je 0.95^{20} .

□

(c) Proč je to problém, když používáme hranici 0.05 u každého testu zvlášť?

Řešení: protože celková pravděpodobnost alespoň jednoho falešného pozitivního výsledku může být mnohem větší než 0.05.

□

(d) (Bonferroniho korekce) Nyní si představme, že každý z 20 testů děláme na hladině $\alpha' = 0.05/20$. Dokažte, že pravděpodobnost, že aspoň jeden z 20 testů falešně zamítne nulovou hypotézu, je nejvýše 0.05, ať už jsou jednotlivé testy nezávislé nebo ne.

Řešení: platí z union boundu

□